



UNIVERSIDADE ESTADUAL DE CAMPINAS
Faculdade de Tecnologia

Brenda Juliane Rodrigues da Silva

Agrupamento de músicas baseado em conteúdo

Limeira
2024

Brenda Juliane Rodrigues da Silva

Agrupamento de músicas baseado em conteúdo

Monografia apresentada à Faculdade de Tecnologia da Universidade Estadual de Campinas como parte dos requisitos para a obtenção do título de Bacharel em Sistemas de Informação.

Orientadora: Profa. Dra. Ana Estela Antunes da Silva

Este trabalho corresponde à versão final da Monografia defendida por Brenda Juliane Rodrigues da Silva e orientada pela Profa. Dra. Ana Estela Antunes da Silva.

Limeira
2024

FOLHA DE APROVAÇÃO

Abaixo se apresentam os membros da comissão julgadora da sessão pública de defesa da monografia para o Título de Bacharel em Sistemas de Informação, a que se submeteu o aluno Brenda Juliane Rodrigues da Silva, em 16 de novembro de 2024 na Faculdade de Tecnologia – FT/UNICAMP, em Limeira/SP.

Profa. Dra. Ana Estela Antunes da Silva
Presidente da Comissão Julgadora - FT/UNICAMP

Prof. Dr. Guilherme Palermo Coelho
FT/UNICAMP

Prof. Dr. Ulisses Martins Dias
FT/UNICAMP

Ata da defesa, assinada pelos membros da Comissão Examinadora, encontra-se no SIGA/Sistema de Fluxo de TCC e na Secretaria de Graduação da Faculdade de Tecnologia.

Agradecimentos

Primeiramente, agradeço a Deus pois sem Ele nada disso seria possível. A minha família que sempre me apoiou e buscou me fornecer todos os recursos necessários para alcançar essa conquista.

Aos meus professores e todos os que contribuíram direta ou indiretamente para que a minha formação acadêmica fosse bem sucedida. Em especial, à Profa. Dra. Ana Estela por toda a paciência e auxílio durante o processo de escrita do presente trabalho.

Resumo

Com o aumento da distribuição de músicas em formato digital, a necessidade de estratégias eficazes para a análise e organização de grandes volumes de dados sonoros ficou ainda mais evidente. No contexto do compositor, que precisa gerenciar sua própria coleção de forma privada e eficiente, ferramentas que facilitem essa gestão tornam-se cruciais. O presente trabalho explora conceitos das áreas de Aprendizado de Máquina e Recuperação de Informação Musical a fim de apresentar possíveis estratégias e seu passo a passo para organizar as músicas de forma automática baseando-se em dois aspectos musicais: timbre e harmonia. Para isso, foram utilizados Mel Frequency Cepstral Coefficients (MFCC) e Cromagramas como descritores dessas características. Além disso, para organizar as músicas separando-as de acordo com a similaridade entre elas, foram utilizados os algoritmos de agrupamento K-Médias, K-Medoids e Hierárquico Aglomerativo. A análise dos agrupamentos obtidos demonstraram que, para a base utilizada, as estratégias se mostram eficazes para organizar músicas baseando-se na similaridade do ponto de vista do timbre e harmonia. Considerando o número de grupos como sendo 3, que foi um dos melhores k encontrados, os valores resultantes do cálculo de coeficiente de silhueta para cada um desses aspectos foram, respectivamente, 0,48 e 0,37.

Abstract

With the increase in digital music distribution, the need for effective strategies for analyzing and organizing large amount of sound data has become even more evident. In the context of the songwriter, who needs to manage their own collection privately and efficiently, tools that facilitate this management become crucial. This work explores concepts from the areas of Machine Learning and Music Information Retrieval to present possible strategies and their step-by-step approach for organizing music automatically based on two musical aspects: timbre and harmony. For this purpose, Mel Frequency Cepstral Coefficients (MFCC) and Chromagrams were used as descriptors of these characteristics. Additionally, to organize the music by separating them according to their similarity, the K-Means, K-Medoids, and Hierarchical Agglomerative clustering algorithms were used. The analysis of the obtained clusters showed that, for the dataset used, the strategies are effective in organizing music based on similarity from the perspective of timbre and harmony. Considering the number of groups as 3, which was one of the best found k values, the resulting silhouette coefficient values for each of these aspects were, respectively, 0.48 and 0.37.

Lista de Figuras

2.1	Impacto da amplitude e frequência em uma onda sonora.	15
2.2	Discretização de uma onda sonora.	15
2.3	Formato de onda e espectograma de um áudio.	16
2.4	Quatro diferentes fatores que influenciam na percepção musical.	17
2.5	Fluxograma dos passos seguidos pelo K-Means.	21
2.6	Fluxograma dos passos seguidos pelo K-Medoids.	22
4.1	Resultado do pré-processamento baseado em cromagrama	29
4.2	Resultados do pré-processamento baseado em MFCC's	29
4.3	Dispersão dos MFCCs considerando apenas os três primeiros coeficientes . . .	32
4.4	Dispersão dos três primeiros MFCCs para a base modificada	32

Lista de Tabelas

4.1	Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo K-Médias para o timbre . .	30
4.2	Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo K-Medoids para o timbre .	30
4.3	Cálculo dos coeficientes de Silhueta e Davies-Bouldin para a execução do algoritmo Hierárquico Aglomerativo para o timbre	31
4.4	Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo K-Médias com os dados de outro artista para o timbre	34
4.5	Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo K-Medoids com os dados de outro artista para o timbre	34
4.6	Resultados dos coeficientes de silhueta e Davies-Bouldin para a execução do algoritmo Hierárquico Aglomerativo com os dados de outro artista para o timbre	35
4.7	Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo K-Médias para o aspecto harmônico	35
4.8	Média, mediana e melhor valor obtidos nas vinte execuções do algoritmo K-Medoids para o aspecto harmônico	36
4.9	Cálculo dos coeficientes de Silhueta e Davies-Bouldin para a execução do algoritmo Hierárquico Aglomerativo para o aspecto harmônico	36
4.10	Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo K-Médias com os dados de outro artista para harmonia	38
4.11	Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo K-Medoids com os dados de outro artista para harmonia	38
4.12	Resultados dos coeficientes de silhueta e Davies-Bouldin para a execução do algoritmo Hierárquico Aglomerativo com os dados de outro artista para harmonia	39
4.13	Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo K-Médias para ambas as características	40
4.14	Média, mediana e melhor valor obtidos nas vinte execuções do algoritmo K-Medoids para ambas as características	40
4.15	Cálculo dos coeficientes de Silhueta e Davies-Bouldin para os agrupamentos baseados nos em ambas as características para o algoritmo Hierárquico Aglomerativo	41

4.16	Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo K-Médias com os dados de outro artista para ambos os aspectos	42
4.17	Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo K-Medoids com os dados de outro artista para ambos os aspectos	42
4.18	Resultados dos coeficientes de silhueta e Davies-Bouldin para a execução do algoritmo Hierárquico Aglomerativo com os dados de outro artista para ambos os aspectos	43

Sumário

1	Introdução	11
1.1	Motivação	11
1.2	Objetivo	12
1.3	Organização da Monografia	13
2	Levantamento bibliográfico	14
2.1	Conceitos fundamentais	14
2.1.1	Características e representação digital do áudio	14
2.1.2	Características da música	16
2.1.3	Processamento de áudio e Recuperação de Informação Musical	17
2.1.4	Descritores de áudio	18
2.1.5	Agrupamento	18
2.1.6	Validação de grupos	21
2.2	Trabalhos correlatos	23
3	Metodologia	25
3.1	Base de dados	25
3.2	Pré-processamento dos dados	25
3.2.1	Harmonia	26
3.2.2	Timbre	26
3.2.3	Ambos os aspectos	26
3.3	Agrupamento	27
3.4	Validação dos grupos	27
3.5	Implementação	27
4	Resultados	28
4.1	Pré-processamento	28
4.2	Agrupamento por Timbre	28
4.3	Agrupamento por Harmonia	33
4.4	Agrupamento considerando ambos os aspectos	37
5	Conclusão	44
5.1	Trabalhos futuros	45
	Referências bibliográficas	47

Capítulo 1

Introdução

A distribuição de músicas por meio digital aumentou muito nas últimas décadas e, com isso, a necessidade de estratégias para analisar informações a partir desse tipo de mídia ficou mais evidente. Atualmente, sistemas de gerenciamento de áudio precisam navegar por milhões de músicas quando necessário buscar informações específicas, o que torna a capacidade de explorar o conteúdo destes de forma eficiente algo imprescindível.

Nesse contexto, a Recuperação de Informação Musical (Music Information Retrieval - MIR) tem sido alvo de diversas pesquisas e engloba abordagens interdisciplinares das mais simples às mais complexas (CASEY et al., 2008), haja vista a natureza multidimensional da música no ponto de vista da informação. Além disso, técnicas de Mineração de Dados e Aprendizado de Máquina têm se mostrado facilitadores fundamentais para manipulação e análise de informações da área.

Há diversas aplicações nas quais essas áreas combinadas podem ser empregadas a fim de solucionar problemas. Exemplos disso são: busca por músicas a partir de um trecho, recomendação de canções, identificação de uso indevido de conteúdo sob direitos autorais, detecção de emoções causadas a partir das músicas e etc (CASEY et al., 2008).

1.1 Motivação

Devido ao aumento de músicas digitais disponíveis, compositores podem encontrar desafios significativos para gerir e organizar sua coleção pessoal de músicas. Ainda que serviços de streaming ofereçam diversas ferramentas para identificação de padrões e organização de

canções, muitos músicos preferem manter suas composições em sigilo a fim de evitar exposição prematura.

Nesse contexto, a necessidade de ferramentas privadas eficazes para categorização de músicas baseada nas características sonoras destas se torna evidente, haja vista que, além de aprimorar a gestão das canções, forneceria ao artista a possibilidade de identificar padrões e relações entre suas obras. Esse processo pode ser mais demorado e menos eficiente se feito de forma manual e menos estruturada.

Considerando que a música possui diversos elementos, como harmonia, ritmo, timbre, tempo e melodia, há diversos aspectos que podem ser levados em consideração no momento de categorizar, isto é, agrupar canções baseando-se em similaridade. Realizar agrupamentos a partir da harmonia, por exemplo, facilitaria ao músico saber quais de suas canções utilizam os mesmos acordes, o que pode auxiliá-lo em suas decisões criativas para futuras composições.

Ademais, a partir do timbre, pode-se identificar que tipo de instrumentos e vozes estão presentes na música. Considerar esse aspecto para realizar esses agrupamentos possibilitaria ao músico determinar quais de suas canções possuem instrumentos predominantes semelhantes. Músicas cujas linhas de guitarra se destacam, por exemplo, estariam na mesma categoria, já canções que utilizam apenas um piano como base, pertenceriam a outro grupo.

Nesse cenário, os algoritmos de agrupamento em Aprendizado de Máquina, cuja finalidade é gerar grupos a partir dos dados, tornam-se convenientes. Estes podem ser utilizados para identificar padrões de forma automática por meio do agrupamento dos dados. Dentre os diversos tipos de algoritmos, estão os denominados particionais, que são simples de parametrizar e serem aplicados, a exemplo do K-Médias (IBM, 2024a).

1.2 Objetivo

O presente trabalho tem como objetivo aplicar conceitos de processamento de áudio e Aprendizado de Máquina a fim de agrupar músicas similares de acordo com seu conteúdo. Para isso, os agrupamentos serão formados individualmente considerando dois diferentes aspectos do áudio: timbre e harmonia.

Os objetivos específicos são:

- Conhecer e aplicar conceitos relacionados a processamento e extração de informações de áudios;

- Aplicar algoritmos de aprendizado de máquina para formar diferentes agrupamentos de acordo com dados que descrevem a harmonia e timbre das canções;
- Propor uma metodologia que possa ser utilizada para identificar quais músicas são similares baseando-se no timbre e na harmonia destas;
- Analisar os resultados obtidos a fim de validar os grupos formados.

1.3 Organização da Monografia

Este trabalho está organizado da seguinte maneira:

- Capítulo 2: apresentação de conceitos fundamentais para melhor compreensão desta monografia. São apresentadas noções introdutórias sobre música, aprendizado de máquina e recuperação de informação musical. Além disso, são apresentados trabalhos correlatos que serão base para a aplicação das metodologias utilizadas.
- Capítulo 3: descrição da metodologia utilizada para a realização dos experimentos.
- Capítulo 4: explanação e análise dos resultados obtidos nos experimentos.
- Capítulo 5: conclusões finais e possíveis temas para futuros trabalhos.

Capítulo 2

Levantamento bibliográfico

Este capítulo descreve conceitos fundamentais para o melhor entendimento desta monografia.

2.1 Conceitos fundamentais

Nessa seção serão abordadas definições introdutórias a respeito de música e aprendizado de máquina.

2.1.1 Características e representação digital do áudio

O **som** é o resultado da propagação de ondas mecânicas, isto é, de uma perturbação no meio que acarreta na vibração do ar (BORATTO et al., 2022). Por se tratar de um movimento ondulatório, é caracterizado por amplitude e frequência. A **amplitude** está relacionada à intensidade, ou seja, ao volume do áudio. Logo, quanto maior a altura da onda, mais intenso é o som. A **frequência** descreve o quão grave ou aguda é a sonoridade, ou seja, quanto menor o número de oscilações por segundo, mais grave é o áudio, como ilustrado pela Figura 2.1.

A onda sonora que ouvimos é contínua e, para representá-la de forma legível ao computador, é necessário submetê-la a um processo de discretização. Essa conversão analógico-digital envolve o processo de amostragem, que consiste na obtenção de **amostras** através da discretização do sinal ao longo do tempo, conforme representado na Figura 2.2. A **taxa de amostragem** determina quantas amostras são representadas por segundo, e todo esse processo está diretamente relacionado à qualidade da representação digital do som (KNEES; SCHEDL, 2016).




Figura 2.1: Impacto da amplitude e frequência em uma onda sonora.
Fonte: Adaptado de MULLA (2022)




Figura 2.2: Discretização de uma onda sonora.
Fonte: Henriques (2016)

Até então o sinal de áudio foi tratado no domínio do tempo, mas é interessante representá-lo no domínio da frequência pois, dessa forma, é possível ver o seu **espectro**, ou seja, a distribuição de cada componente de frequência na construção do sinal resultante. Para essa transformação, é utilizada uma metodologia matemática conhecida como Transformada Discreta de Fourier (DFT) (CARVALHO, s.d.; KNEES; SCHEDL, 2016; MÜLLER, 2016) e o resultado desta é exemplificado na Figura 2.3. No gráfico à esquerda na imagem, o sinal está representado no domínio do tempo e à direita no domínio da frequência. Além disso, um exemplo de algoritmo que aplica a DFT é o Fast Fourier Transform (FFT) (COOLEY; LEWIS; WELCH, 1969) e, aplicando-o, obtemos o **espectrograma** do áudio.




Figura 2.3: Formato de onda e espectrograma de um áudio.
Fonte: (TOPITAL, 2019)

2.1.2 Características da música

O que difere a música de um simples ruído é a periodicidade do som. As características deste possuem um significado específico no meio musical (DONOSO, s.d.). As frequências, por exemplo, correspondem às notas musicais de uma canção. Outras características relevantes são:

1. **Timbre**: refere-se à qualidade que permite a um ouvinte diferenciar dois sons similares, isto é, com mesma intensidade e tonalidade (CREASEY, 2006). Por exemplo, a diferença entre uma voz e um som de piano que estão soando no mesmo tom e com idêntico volume é o timbre.
2. **Harmonia**: refere-se a múltiplas notas entoadas simultaneamente de forma que combinem entre si (BORATTO et al., 2022; OLIVEIRA, 2022).

2.1.3 Processamento de áudio e Recuperação de Informação Musical

A Recuperação de Informação Musical (do inglês, Music Information Retrieval - MIR) é um campo de estudo multidisciplinar definido por Knees e Schedl (2016) como a área preocupada com a extração, análise e uso da informação sobre qualquer tipo de entidade musical em quaisquer níveis de representação. Essas diversas formas de descrever a música (utilizando símbolos, o próprio sinal de áudio e etc.) (MÜLLER, 2016) somadas aos diferentes fatores que influenciam na percepção desse tipo de mídia justificam a complexidade da área.

Há diversas aplicações para a MIR (CASEY et al., 2008), mas o foco deste trabalho é a busca por similaridade, haja em vista que o objetivo é agrupar músicas semelhantes entre si. Tendo isso em mente, é importante levar em consideração os diferentes aspectos envolvidos na percepção musical, conforme descrito na Figura 2.4, para os quais há quatro principais: conteúdo, contexto do usuário, contexto da música e preferências do usuário (KNEES; SCHEDL, 2016). O presente trabalho terá como alvo a extração e comparação de informações baseada no conteúdo da música, isto é, naquilo que pode ser extraído do sinal de áudio em si, como timbre e harmonia.



Figura 2.4: Quatro diferentes fatores que influenciam na percepção musical.
Fonte: Adaptado de Knees e Schedl (2016)

2.1.4 Descritores de áudio

Os descritores de áudio representam as características do som e podem descrever diferentes aspectos da música. Além disso, estes podem ser classificados pelo nível de abstração (CASEY et al., 2008; BORATTO et al., 2022; KNEES; SCHEDL, 2016; MÜLLER, 2016), sendo estes:

1. **Alto nível:** conceitos musicais percebidos pelos humanos, como timbre, melodia, harmonia, ritmo e etc.;
2. **Nível intermediário:** combinação entre descritores de baixo nível e conhecimento de alto nível, a exemplo dos MFCCs, que serão utilizados neste trabalho;
3. **Baixo nível:** descrições estatísticas do sinal que podem ser entendidas pelo computador.

Mel Frequency Cepstral Coefficient (MFCC)

Os MFCCs são descritores calculados para cada “frame” (janela de tempo) do sinal de áudio e buscam representar o timbre do som considerando a audição humana. Esses coeficientes são extraídos a partir do espectrograma da música, que então é submetido às transformações para a escala logarítmica, a escala de Mel e, finalmente, passa pela Transformada Discreta de Cosseno (DCT). Os MFCCs obtidos através desse processo se aproximam da percepção humana da música uma vez que esta não ocorre de maneira linear (KNEES; SCHEDL, 2016; CASEY et al., 2008; BORATTO et al., 2022; KNEES; SCHEDL, 2016; ABDUL; AL-TALABANI, 2022).

Cromagramas

Os cromagramas também são calculados para cada frame da música e os dados que o compõem representam classes de notas musicais. Cada atributo dessa representação corresponde a uma nota da escala cromática¹, de Dó a Si, e engloba todas as oitavas desta. Por exemplo, o descritor que correspondente à nota Dó (C) indica a presença desta na janela de tempo em questão e considera todas as oitavas de C (... , C1, C2, C3...) (MÜLLER, 2016).

2.1.5 Agrupamento

Mineração de dados é o termo utilizado para descrever tarefas que empregam algoritmos a fim de extrair conhecimento de uma base de dados. Uma das áreas intrínsecas a esta é denominada

¹Escala cromática é composta por todas as notas do sistema de música ocidental. Logo, a distância entre as notas é de meio tom (Ex.: Dó, Dó sustenido, Ré, Ré sustenido e etc.) (UFRGS, 2019)

Aprendizado de Máquina (AM) , a qual busca extrair informações a partir de um conjunto de dados de forma automática (CASTRO; FERRARI, 2017).

Dentre as diversas atividades englobadas por essa área está o agrupamento, que corresponde ao processo de organizar um conjunto de objetos, normalmente representados por vetores de características, em grupos, também denominados clusters. Essa organização se dá de forma que os itens presentes no mesmo cluster sejam similares entre si e dissimilares aos demais objetos pertencentes a outros grupos (CASTRO; FERRARI, 2017; HAN, J.; KAMBER; PEI, 2011).

Ademais, dentro da área de AM, há dois principais paradigmas de aprendizagem, isto é, dois principais métodos para que os algoritmos ajustem o seu comportamento com relação aos dados:

1. **Aprendizado supervisionado:** a tarefa baseia-se em um conjunto de dados rotulados, ou seja, objetos para os quais as saídas desejadas são conhecidas.
2. **Aprendizado não supervisionado:** é baseado apenas nos objetos que compõem a base de dados, ou seja, os dados não são rotulados.

O agrupamento é um processo não supervisionado e, devido a isso, para analisar os resultados e decidir se fazem sentido, é necessário ter conhecimento de domínio dos dados. Isso porque, como as saídas desejadas não são conhecidas, é necessário entender o significado dos dados para determinar se o grupo formado faz sentido. Além disso, considerando que encontrar a solução ótima para separação de n objetos em k grupos pode se tornar computacionalmente inviável e que determinar o número de grupos a serem gerados pelo algoritmo é uma tarefa difícil, o agrupamento torna-se uma tarefa um tanto complexa (CASTRO; FERRARI, 2017).

Algoritmos de agrupamento

Há diversos algoritmos que podem seguir diferentes métodos para agrupar dados, dentre estes há duas categorias principais:

1. **Métodos hierárquicos:** estes decompõem a base de dados de forma hierárquica e podem ser aglomerativos ou divisivos. Na abordagem aglomerativa, cada objeto pertence a um grupo individual no início e, nas demais iterações, o algoritmo une os

grupos sucessivamente até que haja um grupo que contenha todos os elementos. Já na forma divisiva, todos os dados pertencem a um único grupo inicialmente e, a cada rodada, os conjuntos são particionados em grupos menores até que cada um esteja em um grupo separado (HAN, J.; KAMBER; PEI, 2011).

2. **Métodos particionais:** dado um conjunto de n objetos, estes particionam os dados em k grupos. Essas abordagens criam uma partição inicial e utilizam um *algoritmo de realocação iterativa* a fim de aprimorar a divisão dos grupos realocando os objetos entre grupos até atingir um critério de parada (CASTRO; FERRARI, 2017).

Dentre os mais diversos algoritmos, há dois a serem destacados: K-Means e K-Medoids.

K-Means

O K-Médias (K-Means) é um algoritmo particional que busca formar os grupos de forma que a similaridade entre os objetos intragrupo seja alta e intergrupo seja baixa. Essa similaridade é mensurada a partir do cálculo das distâncias entre o objeto e o valor médio dos objetos pertencentes ao grupo em questão (centróide).

O algoritmo tem início com a escolha arbitrária de k centróides, sendo k o número de clusters a ser gerado. A partir disso, os objetos são atribuídos ao grupo cuja distância até o centróide seja menor. Então, novos centróides são calculados e os objetos são distribuídos novamente de acordo com a similaridade. Essa alocação é realizada de forma iterativa até que o critério de parada seja atingido, isto é, até que não haja mais alterações nos centróides e mudanças de grupo ou até que o número de iterações máximas seja atingido. Esse processo é descrito pela Figura 2.5.

K-Medoids

O K-Médias é sensível a outliers uma vez que um valor muito distante do centro do grupo pode distorcer substancialmente o resultado final. Isso se dá pois o ponto de referência do grupo (centróide) é obtido a partir de uma média das amostras contidas nesse grupo, logo valores altos impactam consideravelmente o resultado.

O K-Medoids é um algoritmo semelhante ao K-Médias pensado para reduzir essa sensibilidade. Neste, os pontos de referência do grupo, aqui denominados medoides, são necessariamente objetos da própria base, que estão mais centralmente localizados em cada




Figura 2.5: Fluxograma dos passos seguidos pelo K-Means.
Fonte: a própria autora.

grupo. Devido a isso, essa abordagem é mais robusta a dados ruidosos. As etapas seguidas pelo algoritmo são descritas pela Figura 2.6.

Vale ressaltar que o K-Medoids possui um processamento mais custoso do que o proposto pelo K-Means. Devido a essa característica, o método que utiliza Medoids funciona muito bem para bases de dados pequenas, mas não para bases grandes (HAN, J.; KAMBER; PEI, 2011; CASTRO; FERRARI, 2017).

2.1.6 Validação de grupos

Há diversos aspectos que podem ser considerados ao se avaliar o agrupamento formado pelas abordagens citadas, dentre estas os grupos obtidos podem ser avaliados considerando sua qualidade. Essa avaliação pode ser feita de forma externa, ou seja, comparando os grupos formados com uma estrutura de agrupamento já conhecida, ou de forma interna, isto é, apenas avaliando o resultado obtido para determinar se a formação dos grupos está adequada aos dados.

Coefficiente de Silhueta

O coeficiente de silhueta é uma métrica interna utilizada para determinar o quão bem os objetos estão agrupados. Além disso, esse coeficiente pode ser interpretado como sendo o grau de pertinência dos objetos aos seus grupos e assume valores no intervalo de -1 a 1, devendo ser maximizado. Essa medida é calculada a partir da distância média de uma instância aos demais




Figura 2.6: Fluxograma dos passos seguidos pelo K-Medoids.

Fonte: a própria autora.

objetos do grupo ao qual a mesma pertence e da distância média entre essa instância e os demais grupos (CASTRO; FERRARI, 2017; HAN, J.; KAMBER; PEI, 2011).

O coeficiente de silhueta é obtido através da Equação 2.1, sendo A a distância do objeto até o centróide do grupo a que pertence e B a distância mínima entre esse objeto e o centróide de cada um dos demais grupos (IBM, 2024b).

$$\frac{1}{n} \sum_{i=1}^n \frac{B_i - A_i}{\max(A_i, B_i)} \quad (2.1)$$

Índice de Davies-Bouldin

O índice de Davies-Bouldin pode assumir valores positivos de zero a infinito devendo ser minimizado, ou seja, quanto mais próximo de zero melhor. Esse valor é definido a partir da média da métrica de similaridade entre cada grupo e outro mais próximo, sendo que a similaridade corresponde à razão entre distâncias dentro do grupo e entre os demais. Dessa forma, grupos mais distantes entre si e mais densos, isto é, cujos dados estão menos dispersos, resultarão em uma métrica melhor (DAVIES-BOULDIN..., 2024).

O coeficiente é obtido a partir da Equação 2.2, onde k é igual ao número de grupos, S é a distância média entre cada instância do grupo e seu centróide e D é a distância dos centróides dos grupos sendo analisados (PUMA-VILLANUEVA; ZUBEN, 2008; MEDIUM, 2023).

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{S_i + S_j}{D_{ij}} \right) \quad (2.2)$$

2.2 Trabalhos correlatos

Há diversos trabalhos em que o agrupamento de músicas baseado em conteúdo é empregado. No trabalho de Xin Luo Xuezheng Liu (2014) é proposto um framework para extração de informação referente à similaridade entre áudios a partir de MFCCs. Na abordagem utilizada, os autores calcularam esses coeficientes para cada música e, então, utilizaram o K-Means para formar o número de clusters desejados. A partir desses grupos, os autores mediram a distância entre cada cluster a fim de obter a informação de similaridade desejada e obtiveram, em seu melhor experimento, 95.05% de acurácia.

No artigo de Huihui Han et al. (2018), essa mesma metodologia é empregada a fim de criar um sistema para recomendação de músicas baseando-se na similaridade do conteúdo dos áudios, porém, os autores alcançaram acurácia média de 87%. Vale ressaltar que ambos os trabalhos apontaram a necessidade de aprimorar esse processo de manipulação dos dados quanto à sua velocidade, uma vez que essa abordagem pode ser lenta para bases de dados muito grandes.

A partir de um objetivo semelhante, no estudo de Atahan et al. (2021), os autores escolheram uma abordagem diferente e aplicaram tanto algoritmos de classificação quanto o K-Means para realizar agrupamentos e, assim, recomendar músicas baseando-se em similaridade de conteúdo. Esse trabalho preocupou-se em comparar a performance da simples extração de descritores de características das músicas com as características obtidas a partir de codificadores automáticos, isto é, redes neurais projetados para compactar e descompactar dados de entrada (DAVE BERGMANN, 2023).

Ademais, para a extração de características das músicas, foram combinados diversos descritores, dentre estes estão os MFCCs e os Cromagramas. Já os codificadores automáticos foram treinados apenas a partir dos Mel Frequency Cepstral Coefficients. Essa abordagem automática não apresentou melhoras significativas na acurácia das classificações realizadas sobre os dados e, além disso, nenhum dos resultados obtidos em termos de assertividade foi superior a estudos prévios.

Com um objetivo semelhante a esses trabalhos, isto é, obter informações quando à similaridade entre diversas canções, o presente trabalho utilizou os mesmos descritores de características de músicas, ou seja, MFCCs e Cromagramas. Entretanto, para tratar os dados obtidos através da extração desses descritores, foi seguida uma abordagem diferente das descritas em cada trabalho.

Capítulo 3

Metodologia

Este capítulo descreve as técnicas e passo a passo seguidos para tratar os dados e formar os agrupamentos.

3.1 Base de dados

Para a realização dos agrupamentos, foram selecionadas 30 músicas criadas e gravadas pela própria autora, sendo:

- 10 músicas compostas apenas por voz e violão;
- 10 músicas compostas apenas por voz e teclado;
- 10 músicas compostas apenas por voz e ukulele.

Além disso, vale ressaltar que os áudios não passaram por nenhum tratamento após a gravação e têm duração variada entre 1 minuto e 1 minuto e meio. É importante mencionar que as músicas estão em três principais tonalidades, Dó (C), Lá (A) e Mi (E).

Para fins experimentais, após a realização dos agrupamentos, foram adicionadas mais 10 canções gravadas apenas com voz e violão de outro artista para validar a formação de novos grupos. Vale mencionar que estes tem duração entre 30 segundos e 1 minuto.

3.2 Pré-processamento dos dados

Para extrair as características das músicas, foram seguidas diferentes abordagens para cada um dos dois diferentes aspectos levados em consideração. Tanto o timbre quanto harmonia foram

escolhidos pois são relevantes na categorização de músicas uma vez que são características primordiais para a definição da identidade musical de um áudio.

3.2.1 Harmonia

Com o propósito de agrupar as músicas considerando seu aspecto harmônico, a extração dos dados descritivos foi baseada nas notas identificadas no decorrer do áudio. Para isso, o sinal foi decomposto em um *cromagrama*, ou seja, em uma representação na qual há doze atributos, cada um representando a presença de uma nota musical para cada janela de tempo da música.

Ademais, a fim de reduzir a dimensionalidade dos dados resultantes, o domínio do tempo foi desconsiderado da análise. Para tal, foi calculada a média dentre todos os valores obtidos em cada intervalo, resultando em uma base na qual cada música é representada por um vetor 12-dimensional. Vale ressaltar que os valores dos atributos foram normalizados na escala de zero a um.

3.2.2 Timbre

A fim de formar grupos baseando-se no timbre, o método escolhido utilizou os *Mel Frequency Cepstral Coefficients* (MFCC). Foram calculados treze coeficientes para cada janela de tempo da música e, para desconsiderar o aspecto temporal, foi computada a média para os valores medidos em cada frame, conforme um dos métodos para tratamento desse tipo de dado apresentados por Knees e Schedl (2016).

Ademais, os experimentos realizados por M. Hassan Shirali-Shahreza e Sajad Shirali-Shahreza (2010) demonstraram que, ao remover o primeiro coeficiente gerado, a acurácia dos algoritmos aplicados sobre esses dados tende a aumentar. Dessa forma, a base resultante foi composta por vetores 12-dimensionais.

3.2.3 Ambos os aspectos

Para agrupar as músicas considerando os aspectos de timbre e harmonia simultaneamente, além das etapas descritas para o tratamento desses dados individualmente, foi necessário normalizar os MFCCs para uma escala de zero a um. Dessa forma, os valores para os dois tipos de descritores ficaram em uma escala única, o que evitou vieses de dados discrepantes. A base resultante foi composta por vetores 24-dimensionais.

3.3 Agrupamento

Com o objetivo de comparar os resultados, foram escolhidos três algoritmos para realizar os agrupamentos: K-Médias, por ser amplamente utilizado neste contexto, inclusive nos trabalhos correlatos a este; K-Medoids, por ser mais robusto e menos sensível a outliers que o anterior; e o Hierárquico Aglomerativo, já que este não possui uma inicialização arbitrária, o que elimina esse viés dos resultados finais, diferentemente dos anteriores .

Para o algoritmo Aglomerativo, o método de ligação utilizado foi o Ward. Quanto aos algoritmos particionais, K-Médias e K-Medoids, foram feitas 20 iterações variando os valores para o fator de inicialização aleatória e, ao final, foram computadas as médias e medianas para os valores das métricas de avaliação de grupos.

Além disso, para selecionar o número de grupos a ser analisado, foi feito um teste utilizando valores de 2 a 12 e, o que obteve o melhor coeficiente de silhueta, foi escolhido. É importante ressaltar também que, o método para cálculo das distâncias utilizado foi o da distância Euclidiana pois é uma das formas consideradas efetivas para os tipos de descritores escolhidos, conforme Knees e Schedl (2016) e Logan e Salomon (2001).

3.4 Validação dos grupos

A fim de metrificar a qualidade dos grupos formados pelos algoritmos, foram utilizados o coeficiente de silhueta e o índice de Davies-Bouldin. Dessa forma, foi possível avaliar a coesão interna, a separação entre os grupos e a compactação destes.

3.5 Implementação

A fim de aplicar as técnicas mencionadas, foram utilizadas algumas bibliotecas da linguagem de programação Python. Para realizar o processamento de áudio, foi utilizada a biblioteca Librosa e, para aplicar os algoritmos de agrupamento e também calcular as métricas de avaliação de grupos, a biblioteca SKLearn foi escolhida. É importante ressaltar que os códigos e os dados base utilizados estão disponíveis em um repositório público hospedado na plataforma GitHub (<https://github.com/brendajuliane/MusicClustering>)

Capítulo 4

Resultados

Este capítulo descreve os resultados obtidos a partir da aplicação da metodologia descrita.

4.1 Pré-processamento

Após passar pela extração de cromagramas, o resultado obtido para as dez primeiras músicas da base é indicado pela Figura 4.1. Conforme exemplificado, para cada música, há um valor entre 0 e 1 indicando a presença de cada nota. Nas músicas cujos index são 0, 1, 4 e 5, por exemplo, é possível notar que a presença da nota Dó, representada pela letra C, é consideravelmente alta e, de fato, essas músicas se encontram nessa tonalidade.

Além disso, o resultado do processamento para descrever timbre é demonstrado pela Figura 4.2. É possível constatar que os valores dos coeficientes obtidos são próximos, o que é esperado considerando que os dez áudios de amostra, apesar de serem músicas distintas, foram gravados a partir do mesmo instrumento, da mesma voz e com o mesmo equipamento de gravação.

4.2 Agrupamento por Timbre

Considerando a definição de timbre, pode-se considerar que o melhor número de grupos baseando-se exclusivamente nesse aspecto para a base utilizada é 3. Isso porque há somente três tipos diferentes de instrumentos musicais e, apesar da presença de um quarto timbre representado pela voz, o vocal é o mesmo em todos os áudios.

Conforme as Tabelas 4.1, 4.2, 4.3, é possível ver que todos os algoritmos obtiveram resultados semelhantes para os valores de k igual a 2 e 3, que obtiveram o melhor resultado




Figura 4.1: Resultado do pré-processamento baseado em cromagrama
Fonte: a autora




Figura 4.2: Resultados do pré-processamento baseado em MFCC's
Fonte: a autora

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,48	0,48	0,48	0,77	0,77	0,77
3	0,48	0,48	0,48	0,73	0,73	0,73
4	0,42	0,42	0,46	0,89	0,89	0,81
5	0,39	0,40	0,40	0,93	0,92	0,92
6	0,32	0,32	0,38	1,00	1,01	0,88
7	0,29	0,29	0,35	1,00	1,01	0,86
8	0,27	0,27	0,29	0,96	0,95	0,82
9	0,24	0,25	0,27	0,93	0,94	0,78
10	0,22	0,22	0,25	0,94	0,90	0,78
11	0,19	0,20	0,22	0,93	0,90	0,79
12	0,19	0,19	0,22	0,85	0,86	0,73

Tabela 4.1: Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo **K-Médias** para o **timbre**

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,42	0,48	0,48	0,87	0,77	0,77
3	0,46	0,48	0,48	0,77	0,73	0,73
4	0,38	0,38	0,46	0,88	0,88	0,71
5	0,35	0,37	0,43	0,93	0,92	0,69
6	0,32	0,34	0,38	0,93	0,92	0,81
7	0,29	0,30	0,36	0,97	0,96	0,80
8	0,26	0,27	0,32	0,95	0,92	0,69
9	0,24	0,25	0,31	0,94	0,92	0,75
10	0,22	0,23	0,27	0,90	0,90	0,69
11	0,20	0,21	0,24	0,85	0,86	0,69
12	0,18	0,19	0,21	0,84	0,84	0,64

Tabela 4.2: Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo **K-Medoids** para o **timbre**

nº grupos	Silhueta	Davies-Bouldin
2	0.48	0.77
3	0.48	0.73
4	0.42	0.89
5	0.40	0.92
6	0.32	1.01
7	0.31	0.90
8	0.28	0.93
9	0.27	0.87
10	0.25	0.86
11	0.25	0.79
12	0.23	0.83

Tabela 4.3: Cálculo dos coeficientes de Silhueta e Davies-Bouldin para a execução do algoritmo **Hierárquico Aglomerativo** para o **timbre**

para o coeficiente de silhueta, isto é, 0,48. Para o algoritmo K-Médias, conforme a Tabela 4.1, todas as iterações para esses valores de k resultaram na mesma formação de grupos e, conseqüentemente, nos mesmos valores para as métricas de avaliação. Já quanto ao K-Medoids, conforme a Tabela 4.2, para k igual a 3 os resultados foram mais consistentes considerando que as iterações obtiveram resultados menos discrepantes, já que a média para os coeficientes de silhueta é mais próxima de 0,48 do que a média obtida para k igual a 2.

Para k igual a 3, os grupos resultantes seguiram a formação esperada na qual os áudios com o mesmo instrumento ficaram no mesmo grupo. Ou seja, um grupo composto pelas músicas com voz e violão, outro pelas canções com voz e ukulele e o último formado pelos áudios com voz e teclado.

Já para k igual a 2, um grupo foi composto pelos áudios com voz e ukulele e o outro pelas demais músicas. Na Figura 4.1, é possível observar a dispersão dos dados em um espaço tri-dimensional no qual os pontos em vermelho representam as músicas gravadas com teclado, em verde os áudios gravados com ukulele e em azul as canções com violão. Para gerar esse gráfico foram utilizados apenas os três primeiros coeficientes dos doze extraídos.

Apesar de terem obtido valores semelhantes para o coeficiente de silhueta, para o número de grupos como sendo 3, o resultado do cálculo do índice de Davies-Boundin foi melhor comparado ao resultado obtido para k igual a 2, já que se aproxima mais de zero. Isso indica que a qualidade dos agrupamentos formados é melhor em termos de separação entre grupos e compactação destes.




Figura 4.3: Dispersão dos MFCCs considerando apenas os três primeiros coeficientes

Adição de dados de outro artista

Para fins experimentais, foram adicionados à base de dados mais 10 áudios contendo voz e violão gravados por outra pessoa e, na sequência, os experimentos foram feitos novamente. A dispersão dos dados, considerando apenas os três primeiros coeficientes, está representada na Figura 4.4, na qual os pontos em vermelho representam as músicas gravadas com teclado, em verde os áudios gravados com ukulele, em azul as canções com violão e em preto os dados do outro artista.




Figura 4.4: Dispersão dos três primeiros MFCCs para a base modificada

O melhor número de grupos obtidos nesse caso foi 5, conforme as Tabelas 4.4 e 4.6. Para o algoritmo K-Médias, todas as execuções para k igual a 5 obtiveram o mesmo resultado, com coeficiente de silhueta igual a 0,44, o que também foi obtido pela execução do algoritmo Hierárquico Aglomerativo. Já para as iterações do algoritmo K-Medoids, o melhor resultado foi para k igual a 2, conforme Tabela 4.5, já que a média, de 0,41, e mediana, de 0,43, para os coeficientes de silhueta obtidos foram maiores que as métricas das execuções para k igual a 5. Nesse caso, para k igual a 5 o desvio padrão foi de 0,07 e para k igual a 2 foi de 0,03.

Para os agrupamentos com coeficiente de silhueta igual a 0,44 e k igual a 5, a disposição dos grupos ficou da seguinte forma:

- Um grupo composto por 8 músicas sendo estas as que foram adicionadas pertencentes a outro artista;
- Um grupo composto por 12 músicas sendo duas delas do outro compositor e as demais as que foram gravadas utilizando voz e violão;
- Um grupo composto por 10 canções sendo estas as que foram gravadas utilizando voz e teclado;
- Um grupo contendo 4 músicas sendo estas as que foram gravadas utilizando voz e ukulele;
- O último grupo composto pelas 6 canções restantes sendo elas gravadas a partir de voz e ukulele.

4.3 Agrupamento por Harmonia

Todas as músicas da base estão em uma das três seguintes tonalidades: Dó (C), Lá (A) e Mi (E). Entretanto, pode haver uma sobreposição entre elas considerando que muitos acordes utilizados do campo harmônico de A, também são utilizados nas canções que estão na tonalidade de E e vice-versa.

A partir da análise das métricas obtidas para esse experimento, apresentadas pelas Tabelas 4.7, 4.8 e 4.9, nota-se que o melhor valor para o coeficiente de silhueta obtido foi igual a 0,37 considerando o número de grupos igual a 3. Nas execuções do algoritmo K-Médias, conforme a Tabela 4.7, o resultado para k igual a 3 foi igual ao obtido pelo Algoritmo Hierárquico, e o

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,43	0,43	0,43	0,91	0,91	0,91
3	0,42	0,42	0,42	0,82	0,82	0,82
4	0,42	0,42	0,42	0,86	0,86	0,86
5	0,44	0,44	0,44	0,87	0,87	0,87
6	0,40	0,41	0,42	0,90	0,89	0,83
7	0,37	0,39	0,40	0,94	0,89	0,82
8	0,36	0,38	0,39	0,98	0,93	0,88
9	0,33	0,34	0,37	0,95	0,95	0,82
10	0,32	0,32	0,36	0,95	0,94	0,83
11	0,30	0,31	0,35	0,92	0,93	0,76
12	0,28	0,29	0,32	0,91	0,90	0,80

Tabela 4.4: Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo **K-Médias** com os **dados de outro artista** para o **timbre**

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,41	0,43	0,43	0,93	0,91	0,91
3	0,41	0,42	0,42	0,84	0,82	0,82
4	0,38	0,40	0,42	0,90	0,87	0,78
5	0,37	0,40	0,44	0,94	0,89	0,77
6	0,33	0,33	0,42	0,96	0,92	0,77
7	0,31	0,31	0,41	0,98	0,94	0,78
8	0,29	0,30	0,37	0,99	0,98	0,79
9	0,26	0,25	0,37	0,97	0,94	0,79
10	0,24	0,24	0,35	0,98	0,95	0,77
11	0,23	0,22	0,30	0,96	0,98	0,75
12	0,23	0,24	0,32	0,91	0,91	0,72

Tabela 4.5: Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo **K-Medoids** com os **dados de outro artista** para o **timbre**

nº grupos	Silhueta	Davies-Bouldin
2	0.43	0.91
3	0.42	0.82
4	0.42	0.86
5	0.44	0.87
6	0.42	0.89
7	0.39	0.88
8	0.39	0.93
9	0.37	0.85
10	0.35	0.88
11	0.34	0.82
12	0.33	0.82

Tabela 4.6: Resultados dos coeficientes de silhueta e Davies-Bouldin para a execução do algoritmo **Hierárquico Aglomerativo** com os **dados de outro artista** para o **timbre**

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,28	0,28	0,28	1,42	1,41	1,41
3	0,37	0,37	0,37	0,97	0,97	0,97
4	0,34	0,34	0,34	0,96	0,95	0,95
5	0,32	0,34	0,34	0,95	0,96	0,83
6	0,31	0,32	0,34	0,96	0,97	0,85
7	0,31	0,31	0,35	0,92	0,91	0,78
8	0,31	0,32	0,36	0,88	0,89	0,73
9	0,32	0,32	0,35	0,79	0,80	0,65
10	0,32	0,32	0,36	0,77	0,77	0,70
11	0,31	0,32	0,35	0,75	0,75	0,66
12	0,30	0,30	0,34	0,70	0,67	0,60

Tabela 4.7: Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo **K-Médias** para o **aspecto harmônico**

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,26	0,27	0,29	1,42	1,42	1,24
3	0,28	0,37	0,37	1,24	0,97	0,97
4	0,29	0,29	0,34	1,08	1,06	0,87
5	0,28	0,28	0,34	1,06	1,06	0,81
6	0,29	0,30	0,35	0,94	0,95	0,79
7	0,27	0,27	0,35	0,90	0,91	0,73
8	0,26	0,27	0,35	0,88	0,86	0,70
9	0,25	0,24	0,32	0,83	0,82	0,69
10	0,24	0,24	0,31	0,78	0,79	0,61
11	0,23	0,23	0,31	0,78	0,75	0,60
12	0,22	0,22	0,33	0,74	0,74	0,59

Tabela 4.8: Média, mediana e melhor valor obtidos nas vinte execuções do algoritmo **K-Medoids** para o aspecto **harmônico**

nº grupos	Silhueta	Davies-Bouldin
2	0.27	1.43
3	0.37	0.97
4	0.34	0.95
5	0.34	0.91
6	0.34	0.93
7	0.34	0.83
8	0.33	0.83
9	0.35	0.73
10	0.35	0.68
11	0.34	0.64
12	0.33	0.62

Tabela 4.9: Cálculo dos coeficientes de Silhueta e Davies-Bouldin para a execução do algoritmo **Hierárquico Aglomerativo** para o aspecto **harmônico**

mesmo em todas as iterações. Quanto ao algoritmo K-Medoids, apesar do resultado não ter sido o mesmo em todas as iterações, para k igual a 3 a mediana do cálculo do coeficiente de silhueta foi melhor. A disposição dos grupos ficou da seguinte forma:

- Um grupo contendo 9 canções, todas na tonalidade de Dó (C);
- Um grupo contendo 14 canções, sendo uma delas na tonalidade de C, sete em Lá (A) e as demais em Mi (E);
- Um grupo contendo 7 canções, sendo uma delas em C, três em A e as demais em E.

Nota-se que há canções em C que também foram atribuídas a grupos majoritariamente compostos por músicas em E e A. Isso pode ter ocorrido devido a essas notas também comporem a escala maior de Dó o que, portanto, pode tornar a presença delas comum na melodia e progressão de acordes tocadas nas músicas em questão.

Adição de dados de outro artista

Após a repetição desse experimento com a adição dos dados de outro artista, os três algoritmos apontaram melhores valores para k diferentes entre si. Para o algoritmo K-Médias, segundo a Tabela 4.10, o melhor k encontrado foi 4, isso porque os valores da média e mediana, ambos iguais a 0,37, para os coeficientes de silhueta foram os melhores. Já para o Hierárquico, conforme Tabela 4.12, o melhor k foi 10, com um coeficiente de silhueta igual a 0,40.

Para as execuções do algoritmo K-Medoids, conforme Tabela 4.11, o melhor valor para o coeficiente de silhueta de 0,40 não foi sido obtido em nenhuma das iterações para $k=10$, diferentemente do que acontece para o K-Médias. Nesse caso, o melhor k encontrado foi 5, cujas média e mediana, de 0,30 e 0,32 respectivamente, foram as melhores.

4.4 Agrupamento considerando ambos os aspectos

Para os agrupamentos que consideram ambos os aspectos simultaneamente, o melhor k obtido para todos os algoritmos foi 3, conforme as Tabelas 4.13, 4.14, 4.15. Tanto para o K-Médias quanto para o K-Medoids, as melhores médias e medianas para o coeficiente de silhueta foram obtidas para este valor de k . O melhor valor para o coeficiente de silhueta foi de 0,34 e a disposição dos grupos ficou da seguinte forma:

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,29	0,29	0,29	1,37	1,37	1,37
3	0,35	0,35	0,35	1,08	1,08	1,07
4	0,37	0,37	0,37	0,96	0,96	0,96
5	0,35	0,36	0,37	0,95	0,97	0,83
6	0,35	0,36	0,37	0,97	0,96	0,87
7	0,34	0,35	0,37	0,96	0,96	0,82
8	0,35	0,37	0,38	0,88	0,87	0,80
9	0,34	0,37	0,39	0,87	0,87	0,77
10	0,30	0,30	0,40	0,87	0,87	0,73
11	0,31	0,29	0,39	0,86	0,87	0,69
12	0,28	0,28	0,37	0,83	0,84	0,64

Tabela 4.10: Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo **K-Médias** com os **dados de outro artista** para **harmonia**

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,27	0,29	0,29	1,39	1,37	1,37
3	0,26	0,24	0,35	1,37	1,28	1,07
4	0,29	0,30	0,37	1,17	1,11	0,89
5	0,30	0,32	0,36	1,09	1,08	0,85
6	0,28	0,28	0,36	1,10	1,07	0,85
7	0,26	0,27	0,36	1,07	1,04	0,89
8	0,25	0,24	0,37	1,04	1,06	0,83
9	0,24	0,23	0,37	1,01	1,01	0,76
10	0,24	0,23	0,32	0,96	0,92	0,72
11	0,22	0,22	0,27	0,94	0,93	0,78
12	0,22	0,23	0,29	0,89	0,89	0,75

Tabela 4.11: Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo **K-Medoids** com os **dados de outro artista** para **harmonia**

nº grupos	Silhueta	Davies-Bouldin
2	0.27	1.37
3	0.35	1.08
4	0.37	0.96
5	0.36	0.97
6	0.37	0.92
7	0.37	0.95
8	0.37	0.85
9	0.38	0.80
10	0.40	0.72
11	0.34	0.79
12	0.33	0.75

Tabela 4.12: Resultados dos coeficientes de silhueta e Davies-Bouldin para a execução do algoritmo **Hierárquico Aglomerativo** com os **dados de outro artista** para **harmonia**

- Um grupo contendo 14 músicas, sendo:
 - 7 músicas com o teclado cujas tonalidades são E ou A;
 - 7 músicas com o ukulele cujas tonalidades são C, E ou A.
- Um grupo contendo 9 músicas, sendo:
 - 3 músicas com o teclado na tonalidade de C;
 - 3 músicas com o violão na tonalidade de C;
 - 3 músicas com o ukulele também na tonalidade de C;
- Um grupo contendo 7 músicas, sendo:
 - Todas as músicas com o violão nas tonalidades de A, E e C.

Adição de dados de outro artista

Após a repetição desse experimento com a adição dos dados de outro artista, concluí-se que os algoritmos apontaram melhores valores de k diferentes. Conforme Tabela 4.18, para o Hierárquico Aglomerativo, o melhor coeficiente de silhueta obtido foi de 0,37 para k igual a 9 e 10, sendo que, entre esses valores de k , o coeficiente de Davies-Bouldin foi melhor para $k = 10$.

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,25	0,25	0,25	1,50	1,50	1,50
3	0,34	0,34	0,34	1,06	1,06	1,06
4	0,30	0,31	0,31	1,07	1,05	0,96
5	0,28	0,29	0,32	1,05	1,03	0,97
6	0,29	0,28	0,32	1,01	0,99	0,93
7	0,29	0,29	0,33	0,98	0,97	0,89
8	0,29	0,29	0,33	0,91	0,90	0,78
9	0,29	0,28	0,33	0,87	0,85	0,73
10	0,29	0,28	0,33	0,81	0,80	0,70
11	0,28	0,28	0,33	0,74	0,75	0,64
12	0,27	0,27	0,32	0,75	0,75	0,64

Tabela 4.13: Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo **K-Médias** para **ambas as características**

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,25	0,25	0,26	1,47	1,50	1,33
3	0,28	0,34	0,34	1,26	1,06	1,06
4	0,24	0,27	0,31	1,21	1,16	0,89
5	0,26	0,26	0,32	1,07	1,07	0,86
6	0,26	0,26	0,30	1,03	1,02	0,81
7	0,24	0,25	0,30	1,01	1,00	0,78
8	0,23	0,23	0,29	0,98	0,99	0,75
9	0,22	0,22	0,29	0,94	0,98	0,71
10	0,20	0,20	0,29	0,91	0,92	0,71
11	0,19	0,20	0,25	0,86	0,87	0,60
12	0,18	0,18	0,28	0,82	0,84	0,58

Tabela 4.14: Média, mediana e melhor valor obtidos nas vinte execuções do algoritmo **K-Medoids** para **ambas as características**

nº grupos	Silhueta	Davies-Bouldin
2	0.25	1.52
3	0.34	1.06
4	0.31	1.05
5	0.31	0.97
6	0.32	0.95
7	0.31	0.92
8	0.33	0.89
9	0.33	0.81
10	0.33	0.69
11	0.33	0.75
12	0.33	0.60

Tabela 4.15: Cálculo dos coeficientes de Silhueta e Davies-Bouldin para os agrupamentos baseados nos em **ambas as características** para o algoritmo **Hierarquico Aglomerativo**

Já para o algoritmo K-Médias, o melhor k obtido foi 4 com coeficiente de silhueta igual a 0,35 para todas as suas execuções, conforme Tabela 4.16. Quanto ao K-Medoids, conforme Tabela 4.17, cuja média e mediana para os coeficientes de silhueta, de 0,28 e 0,30 respectivamente, foram as melhores.

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,25	0,25	0,25	1,52	1,52	1,51
3	0,31	0,31	0,31	1,19	1,19	1,19
4	0,35	0,35	0,35	1,02	1,01	1,00
5	0,33	0,34	0,34	1,02	1,01	0,93
6	0,33	0,33	0,34	1,02	1,02	0,91
7	0,33	0,34	0,36	0,97	0,94	0,85
8	0,31	0,32	0,36	0,99	1,00	0,87
9	0,31	0,33	0,36	0,92	0,90	0,76
10	0,29	0,29	0,36	0,92	0,95	0,76
11	0,28	0,28	0,35	0,87	0,86	0,71
12	0,26	0,26	0,32	0,86	0,87	0,64

Tabela 4.16: Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo **K-Médias** com os **dados de outro artista** para **ambos os aspectos**

Média, Mediana e Melhor valor						
nº grupos	Silhueta			Davies-Bouldin		
2	0,22	0,25	0,25	1,58	1,51	1,46
3	0,25	0,26	0,31	1,33	1,29	1,19
4	0,26	0,28	0,35	1,20	1,16	1,01
5	0,28	0,30	0,34	1,10	1,10	0,88
6	0,27	0,29	0,33	1,10	1,07	0,89
7	0,27	0,26	0,35	1,07	1,05	0,92
8	0,27	0,28	0,36	1,03	1,00	0,85
9	0,24	0,24	0,33	0,99	0,96	0,84
10	0,24	0,23	0,33	0,94	0,94	0,79
11	0,23	0,23	0,32	0,91	0,91	0,78
12	0,21	0,22	0,30	0,89	0,90	0,75

Tabela 4.17: Média, mediana e melhor valor obtidos para os coeficientes de silhueta e Davies-Bouldin nas vinte execuções do algoritmo **K-Medoids** com os **dados de outro artista** para **ambos os aspectos**

nº grupos	Silhueta	Davies-Bouldin
2	0.24	1.51
3	0.31	1.21
4	0.35	1.01
5	0.34	1.01
6	0.34	0.94
7	0.36	0.93
8	0.35	0.89
9	0.37	0.87
10	0.37	0.80
11	0.32	0.85
12	0.32	0.75

Tabela 4.18: Resultados dos coeficientes de silhueta e Davies-Bouldin para a execução do algoritmo **Hierárquico Aglomerativo** com os **dados de outro artista** para **ambos os aspectos**

Capítulo 5

Conclusão

Este trabalho realizou experimentos a fim de agrupar músicas similares entre si considerando dois aspectos musicais: timbre e harmonia. Isso foi possível através da aplicação de algoritmos de agrupamento, como o K-Médias, K-Medoids e Hierárquico Aglomerativo, e técnicas de pré-processamento de áudio.

A partir da base escolhida, composta por apenas 30 canções gravadas pela autora do presente trabalho, foi possível extrair MFCCs, isto é, coeficientes calculados de forma que se aproximem do ouvido humano para representar o timbre, e Cromagramas, que representam a presença das notas em cada música.

Para os agrupamentos que utilizaram-se dos MFCCs para considerar apenas o aspecto do timbre, foi possível notar que os grupos formados para $k = 3$ realmente fazem sentido do ponto de vista musical. O coeficiente de silhueta obtido nesse caso foi de 0,48 e, considerando que este varia de -1 a 1 sendo mais próximo do valor máximo melhor, foi um bom resultado. Já para o índice de Davies-Bouldin o valor resultante foi de 0,73 e, levando em conta que este varia entre 0 e infinito sendo o mais próximo do mínimo melhor, foi um bom resultado comparado aos demais valores de k nos experimentos em questão.

Ao acrescentar músicas de outro artista na base, gravados da mesma forma que as demais apenas com voz e violão, a formação dos grupos obteve resultados muito próximos ao esperado do ponto de vista musical, com $k = 5$ e coeficientes de Silhueta e Davies-Bouldin iguais a, respectivamente, 0,44 e 0,77. Vale ressaltar que os áudios não passaram por nenhum tratamento pós gravação, apenas pelo pré-processamento descrito no Capítulo 3. Logo, ruídos durante a gravação podem influenciar nos resultados e gerar outliers.

Para os agrupamentos que utilizaram os Cromagramas para obter informações relacionadas à harmonia das músicas, os grupos formados também fazem sentido do ponto de vista musical. Para $k = 3$, o coeficiente de Silhueta e Davies-Bouldin são 0,37 e 0,97. Já os agrupamentos formados a partir da mistura de ambos os aspectos obtiveram um coeficiente de silhueta igual a 0,34 para $k = 3$. Além disso, a formação dos grupos também seguiu uma lógica válida do ponto de vista musical, uma vez que timbres e/ou progressões de notas próximas ficaram nos mesmos grupos.

Ademais, a influência de cada algoritmo na formação dos grupos ficou ainda mais evidente nos experimentos adicionando as músicas de outro artista para os agrupamentos baseados em harmonia e em ambos os aspectos. O algoritmo Hierárquico Aglomerativo se mostrou eficaz em encontrar os melhores resultados com apenas uma execução devido à sua forma de inicialização não depender de fatores arbitrários, diferentemente dos algoritmos particionais utilizados.

Além disso, ficou explícito nos experimentos que as execuções do K-Médias conseguiram obter resultados mais consistentes, isto é, apesar de variar o fator de inicialização aleatória, os agrupamentos formados para um determinado k geralmente eram os mesmos. O K-Medoids, por outro lado, constantemente obteve resultados diferentes. Isso ocorre devido à sua forma de inicialização que, por utilizar dados da própria base como referência para formação dos grupos, pode variar bastante a depender da escolha.

5.1 Trabalhos futuros

Como pauta para futuros trabalhos, seria interessante avaliar o impacto do ruído sonoro na formação dos grupos, uma vez que as canções utilizadas no experimento não passaram por nenhum tratamento após a gravação. Além disso, é importante também avaliar o desempenho da metodologia empregada para grandes volumes de dados.

A escolha para o melhor valor de k também é algo a ser avaliado. A metodologia seguida neste trabalho se baseou em uma análise exploratória na qual um intervalo de valores para k foi testado, o que não é uma estratégia escalável considerando o esforço computacional necessário para grandes volumes de dados.

Outro ponto importante é a escolha do método para cálculo de distâncias a ser utilizado. Na metodologia empregada, o método utilizado foi o da distância Eucliana, mas seria interessante

avaliar outros métodos para identificar o impacto nos resultados. Além disso, a escolha dos descritores de áudio também é uma hipótese a ser avaliada em futuros trabalhos considerando que há diversos tipos de descritores que podem ser retirados desse tipo de dado.

Referências bibliográficas

ABDUL, Z. K.; AL-TALABANI, A. K. Mel Frequency Cepstral Coefficient and its Applications: A Review. **IEEE Access**, v. 10, p. 122136–122158, 2022. DOI: 10 . 1109 / ACCESS . 2022 . 3223444.

ATAHAN, Y. et al. Music Genre Classification Using Acoustic Features and Autoencoders. In: 2021 Innovations in Intelligent Systems and Applications Conference (ASYU). [S.l.: s.n.], 2021. P. 1–5. DOI: 10 . 1109 / ASYU52992 . 2021 . 9598979.

BORATTO, T.; VIEIRA, R.; OLIVEIRA, J. P.; SCHIAVONI, F. Recuperação de informação musical como ferramenta para análise sonora: uma inicialização. In: RECUPERAÇÃO de informação musical como ferramenta para análise sonora: uma inicialização. [S.l.: s.n.], ago. 2022.

CARVALHO, M. A. G. **SI701 Multimídia, Digitalização de sinais**. [S.l.: s.n.]. https://drive.google.com/file/d/1D2tiCNzswRgYH7R1XhXNouSjLSc_A40G/view?usp=sharing. [Accessed 2024-06-20].

CASEY, M. A. et al. Content-Based Music Information Retrieval: Current Directions and Future Challenges. **Proceedings of the IEEE**, v. 96, n. 4, p. 668–696, 2008. DOI: 10 . 1109 / JPROC . 2008 . 916370.

CASTRO, L. de; FERRARI, D. **Introdução a mineração de dados**. [S.l.]: Saraiva Educação S.A., 2017. ISBN 9788547200992. Disponível em: <<https://books.google.com.br/books?id=SSlrDwAAQBAJ>>.

COOLEY, J. W.; LEWIS, P. A. W.; WELCH, P. D. The Fast Fourier Transform and Its Applications. **IEEE Transactions on Education**, v. 12, n. 1, p. 27–34, 1969. ISSN 1557-9638. DOI: 10 . 1109 / TE . 1969 . 4320436.

CREASEY, D. P. An exploration of sound timbre using perceptual and time-varying frequency spectrum techniques., 2006.

DAVE BERGMANN, C. S. (Ed.). **IBM**. 2023. Disponível em: <<https://www.ibm.com/br-pt/topics/autoencoder>>. Acesso em: 20 jun. 2024.

DAVIES-BOULDIN Score. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.metrics.davies_bouldin_score.html>. Acesso em: 20 jun. 2024.

DONOSO, J. P. **Som e acústica**. [S.l.: s.n.]. https://www.ifsc.usp.br/~donoso/fisica_arquitetura/12_som_acustica_1.pdf. [Accessed 2024-06-20].

HAN, H.; LUO, X.; YANG, T.; SHI, Y. Music Recommendation Based on Feature Similarity. In: 2018 IEEE International Conference of Safety Produce Informatization (IICSPI). [S.l.: s.n.], 2018. P. 650–654. DOI: 10.1109/IICSPI.2018.8690510.

HAN, J.; KAMBER, M.; PEI, J. **Data Mining: Concepts and Techniques**. [S.l.]: Elsevier Science, 2011. (The Morgan Kaufmann Series in Data Management Systems). ISBN 9780123814807. Disponível em: <<https://books.google.com.br/books?id=pQws07tdpjoC>>.

HENRIQUES, F. (Ed.). **Quantize**. 2016. Disponível em: <<https://quantize.com.br/como-funciona-a-conversao-analogico-digital/>>. Acesso em: 19 jun. 2024.

IBM (Ed.). **K-Médias**. 2024. Disponível em: <<https://www.ibm.com/docs/pt-br/db2/11.5?topic=building-k-means-clustering>>. Acesso em: 27 jul. 2024.

IBM (Ed.). **Opções de Modelo do Nó Cluster Automático**. 2024. Disponível em: <<https://www.ibm.com/docs/pt-br/spss-modeler/18.5.0?topic=node-auto-cluster-model-options>>. Acesso em: 5 ago. 2024.

KNEES, P.; SCHEDL, M. **Music Similarity and Retrieval: An Introduction to Audio- and Web-based Strategies**. [S.l.: s.n.], 2016. Disponível em: <<https://api.semanticscholar.org/CorpusID:65318432>>.

LOGAN, B.; SALOMON, A. A music similarity function based on signal analysis. In: IEEE International Conference on Multimedia and Expo, 2001. ICME 2001. [S.l.: s.n.], 2001. P. 745–748. DOI: 10.1109/ICME.2001.1237829.

MEDIUM (Ed.). **Métricas de Agrupamento: Coeficiente de Silhueta, Índice de Davies-Bouldin e Índice de Calinski-Harabasz**. 2023. Disponível em: <<https://medium.com/@kalimarapeleteiro/m%C3%A9tricas-de-agrupamento-coeficiente-de-silhueta-%C3%ADndice-de-davies-bouldin-e-%C3%ADndice-de-9462b87ce676>>. Acesso em: 10 ago. 2024.

MULLA, R. (Ed.). **Kaggle**. 2022. Disponível em: <<https://www.kaggle.com/code/robikscube/working-with-audio-in-python/notebook>>. Acesso em: 19 jun. 2024.

MÜLLER, M. **Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications**. [S.l.]: Springer International Publishing, 2016. ISBN 9783319357652. Disponível em: <<https://books.google.com.br/books?id=Wl8ivgAACAAJ>>.

OLIVEIRA, C. de (Ed.). **O que é harmonia?** 2022. Disponível em: <<https://www.cifraclub.com.br/blog/o-que-e-harmonia/>>. Acesso em: 20 jun. 2024.

PUMA-VILLANUEVA, W.; ZUBEN, F. Índices de validação de agrupamentos. **Departamento de Engenharia de Computação e Automação Industrial (DCA)**, 2008.

SHIRALI-SHAHREZA, M. H.; SHIRALI-SHAHREZA, S. Effect of MFCC normalization on vector quantization based speaker identification. In: THE 10th IEEE International Symposium on Signal Processing and Information Technology. [S.l.: s.n.], 2010. P. 250–253. DOI: 10.1109/ISSPIT.2010.5711789.

TOPITAL (Ed.). **Topital**. 2019. Disponível em: <<https://www.toptal.com/algorithms/shazam-it-music-processing-fingerprinting-and-recognition>>. Acesso em: 5 out. 2024.

UFRGS (Ed.). **Escala Cromática**. 2019. Disponível em: <<https://www.if.ufrgs.br/tex/fis01043/20012/Alexandre/escalacromatica.html>>. Acesso em: 25 nov. 2024.

XIN LUO XUEZHENG LIU, R. T. Content-based retrieval of music using mel frequency cepstral coefficient (MFCC). **COMPUTER MODELLING AND NEW TECHNOLOGIES**, 2014.